같은 악보에서 나온 여러 연주의 차이 가운데, 청취자들이 함께 듣는 부분과 각자 다르게 듣는 부분은 연주의 어느 층에 있는가?

RQ1. 연주 층을 세 층으로 나눌 수 있는가, 각 층은 얼마나 크고 안정적인가**?**
RQ2. 청취자 층이 공유 축 **+** 개인 감도로 나뉘는지, 감도는 특성인지**?**
RQ3. 어느 층에서 합의하고 어느 층에서 갈라지는가**?**

1. 출발점**:** 기존 측정은 주로 **"**곡**"**을 보고**,** 해석은 설명되지 않는다

근거 **1** · 평가 예측 모델이 곡을 맞힌다

- 처음 보는 곡에서는 평균 평가와의 순위 상관 → **0.20(MERT 0.203, MuQ 0.206)**이었고, 처음 보는 연주자에서는 **0.60(0.599, 0.629)** (Reliability of Uncertainty-Aware Listener-Rating Prediction for Piano Performances Under Distribution Shifts, Electronics, 2026)
    - 데이터**:** PercePiano**.** 사람 연주 **1,072**구간, 유효 평가 **14,726**행, 평가자 **63**명**.** **MIDI**를 사운드폰트 **2**종**(FluidR3, Salamander)**으로 오디오화한 뒤 **MERT·MuQ** 임베딩
    - 같은 문제를 다룬 다른 논문의 저자도 모델이 "연주자 고유 표현보다 곡의 특성을 잡는다"고 표기 (Audio Foundation Models Outperform Symbolic Representations for Piano Performance Evaluation, arXiv, 2026)
    - 데이터**:** PercePiano **1,202**구간, 곡 단위 **4**겹 교차검증**.** 보조 검증으로 **ASAP, MAESTRO, PSyllabus** 사용

근거 **2** · 사람 평가 자체도 곡 차이에 기대고 있다

- **D960(F.Schubert Sonata in B flat M)**에서 구간 전체로 보면 신뢰도가 높지만, 같은 단위 안으로 좁히면 떨어지는 차원이 존재함
    - **bright→dark**는 **ICC(1,k) 0.77**에서 단위 내 **−0.06**으로**, pleasant→dark**는 **0.81**에서 **0.02**로 떨어짐
    - 데이터**:** PercePiano **(Park et al., 2024)**의 **Schubert D960 2·3**악장**. D960** 구간을 **40**개 이상 평가한 평가자 **41**명**.**
        - **ICC(1,k)**는 **D960** 구간 전체**(**무표정 렌더 포함**)**로, 단위 내 신뢰도는 사람 연주만으로 계산
- 단위 안에서 **0.5** 이상이 남는 차원은 **D960**에서 **7**개**, WoO 80**에서 **fast→slow** 하나**(0.52)**뿐이었음 **(PercePiano** 데이터셋 감사**)**
    - 데이터**:** PercePiano**의 D960** 구간과 **Beethoven WoO 80** 구간**. WoO 80**은 **B3** 그룹 평가자 **11**명이 평가함

근거 **3** · **IdioMap**의 작곡가 판정도 주로 악보 내용을 따름 (IdioMap에서의 보조분석)

- 300음 창마다 정답 작곡가에 대한 점수 CE = −log p(정답 작곡가)를 제곱합으로 나눔. 결과는 곡 37.7% + 위치 26.4% = 64.1%, 연주는 많아야 35.9%였음. 연주 몫은 창 번호로 맞추면서 생긴 어긋남을 포함한 상한
    - 데이터: ASAP (Foscarin et al., 2020) 테스트 분할. 연주당 최대 20창. Aria 임베딩 → 표준화 → model_D 투영 헤드 → 작곡가 중심 7개 → softmax(T=0.1). 연주가 2개 이상인 셀이 2개 이상 있는 곡 34개, 셀 352개, 값 2,062개.
- 같은 저장소의 이전 분석에서 7개 작곡가 확률 벡터를 나눴을 때는 곡 97.1% / 위치 1.2% / 연주 1.7%
    - 데이터: ASAP 전체 분할(학습 포함) 152곡, 창 10,062개, 셀 1,453개, model_D, T=0.1.

근거 **4** · **Aria**는 기계와 사람은 가르지만 사람끼리는 거의 못 가른다

- 무표정 렌더와 사람 사이 거리는 사람끼리 거리의 5.50배(표준화하면 4.31배). 같은 단위 사람 쌍에서 Aria 거리와 지각 차이의 상관은 0.023–0.136(표준화하면 최대 0.146)이었고, 템포 숫자 하나(log_tempo)는 0.477
    - 데이터: PercePiano D960. 64개 단위, 같은 단위 사람 연주 쌍 4,213개. Aria 임베딩(loubb/aria-medium-embedding), partitura·parangonar로 정렬한 손 특징 847구간.
- 템포를 ×0.8/×1.2로 바꾼 변화는 사람끼리 거리의 6–13%만큼, 세기 ±10은 14–21%만큼만 보임
    - 데이터: ASAP의 Schubert 즉흥곡 D899 3번. 사람 연주자 12명 × 2개 구간 × 창 3개 = 72창.
- 이렇게 둔감한 이유는 학습할 때 템포 ±20%, 세기 ±10 증강을 썼기 때문(Bradshaw et al., 2025, "Scaling Self-Supervised Representation Learning for Symbolic Piano Performance", ISMIR 2025)
    - 데이터: 대규모 피아노 전사 MIDI로 자기지도 학습. 증강 수치는 IdioMap 환경에 설치된 aria 코드(커밋 172de049)에서도 확인

→ 결론: 비교는 같은 곡 같은 구간(단위) 안에서 한다.

→ 설계 조건: 단위는 창 번호가 아니라 악보 위치(마디)로 맞춘다 ← IdioMap 분해에서 창 어긋남이 연주 몫에 섞였기 때문. PercePiano 구간은 마디 단위로 잘려 있고(파일명의 Nbars_segment) (Park et al., 2024), ASAP은 악보-연주 정렬을 제공 (Foscarin et al., 2020).

2. 연주 쪽을 나눔 → **RQ1**

- 개성은 무표정 렌더가 아니라 사람 연주의 평균을 기준으로 재야 한다는 주장이 존재 (Wöllner, 2013, "How to quantify individuality in music performance?", Frontiers in Psychology)

    - 데이터: 의견 논문이라 자체 데이터는 없다. **Repp(1997)**의 평균 타이밍 피아노 연주 연구와 지휘자 모션캡처 연구들을 근거
- 연주에는 악구 구조가 정하는 공통 제약이 있고, 그 안에서 개인 변동이 크다 (Repp, 1992, "Diversity and commonality in music performance", JASA)
    - 데이터: **Schumann "Träumerei"** 상업 녹음 **28**개의 음 간격**(IOI)**을 측정함
- "악보 그대로"라는 기준점으로 **PercePiano**의 무표정 렌더**(Score, Score2)**를 쓴다 (Park et al., 2024)
    - 데이터: **PercePiano** 구간마다 들어 있는 렌더. 악보의 셈여림 기호를 반영했는지는 아직 확인하지 않음
- 두 기준점을 합친 문자 / 관습 / 개인 세 층은 직접 설계
    - 데이터(예정): **ASAP**에서 연주가 **6**개 이상인 곡 **60**개**(652**연주**)**, **PercePiano D960.**

3. 청취자 쪽을 나눔 → **RQ2**

- 단위 내 신뢰도는 **dry→wet 0.88, clean→blurred 0.84, fast→slow 0.71, convincing 0.43**이었음
- 개인 감도 **w**는 평균 **0.70–0.97**, 반분 신뢰도 **0.47–0.87**. 설득력 선호 **β**의 반분 신뢰도는 **0.21–0.48** (우리 분석, **R5)**
    - 데이터(위 두 항목): **PercePiano D960**, 평가자 **41**명. "모르겠음"(0/8/9) 응답은 결측으로 처리
- 평가자 분석을 **D960**으로 제한한 이유는 평가자-곡 혼입입니다. 평가자 **11**명은 **WoO 80·D935**만, **54**명은 **D960**만 평가했습니다.
    - 데이터: **PercePiano** 전체 평가 자료 total_2rounds.csv, 평가자 **ID 65**개.
- 다른 팀도 같은 데이터에서 평가자-구간 그래프가 끊겨 전체 신뢰도를 추정할 수 없다고 보고 (Reliability of Uncertainty-Aware Listener-Rating Prediction…, Electronics, 2026)
- "공유 축 + 개인 감도·선호" 두 층으로 정의

4. 둘을 겹침 → **RQ3 (**핵심**)**

연주 쪽 분해 연구

- **(Repp, 1992).** 데이터는 위와 같이 **Träumerei** 녹음 **28**개

청취자 반응 연구들은 연주 층과 겹치지 않았다

- **194**명이 연주를 자유롭게 묘사했는데, 같은 연주에 대한 묘사 일치도가 **16%**, 다른 연주끼리가 **15%**였다. (Cancino-Chacón et al., 2020, "On the Characterization of Expressive Performance in Classical Music: First Results of the Con Espressione Game")
    - 데이터: 유명 피아니스트 녹음과 **MIDI** 렌더를 합쳐 **9**개 발췌 **45**개 연주. 묘사 **1,515**건.

- 청취자는 타이밍 단서만으로 연주자를 식별할 수 있었다. (Gingras et al., 2011, "Perceiving musical individuality")
    - 데이터: 오르가니스트 6명이 친 Scheidt 코랄 1악구, 발췌 30개. 비음악가 20명과 음악가 20명.
- 두 연주가 비슷하게 들리는 정도는 절대 템포와 템포×음량으로 가장 잘 예측되었음 (Timmers, 2005, "Predicting the similarity between expressive performances of music from measurements of tempo and dynamics", JASA)
    - 데이터: Chopin 전주곡과 Mozart 소나타의 연주들. 청취자 40명.
- PercePiano 후속 예측 연구들은 평균 평가만 썼음. (Electronics, 2026), (arXiv 2601.19029, 2026)

가장 가까운 선행연구: 연주와 청취자를 작은 규모로 함께 다룸

- 평균 연주는 품질 공동 2위, 개성 뒤에서 2위였다. 다만 평균 연주의 우위는 통계적으로 신뢰할 수 없었고, 평가자 본인 연주 점수를 빼면 3위였음. 평가자 12명의 순위를 PCA하면 유의 성분이 5개로, 평가자마다 다른 측면에 다른 가중치를 줌 (Repp, 1997, "The Aesthetic Quality of a Quantitatively Average Music Performance: Two Preliminary Experiments", Music Perception, 실험 1)
    - 데이터: Schumann "Träumerei". Yale 대학원생 10명의 Disklavier 연주와, 타이밍·셈여림을 함께 평균한 연주 1개를 합쳐 11개. 아티큘레이션·페달은 고정. 평가자 12명.
- 전문가 평균이 1위였지만 다른 3개와 사실상 동률이었음. 품질과 개성 평가는 r = −.73. 학생 연주가 전문가 연주보다 높게 평가되었고, Repp는 이것을 "역설"이라 부름 (Repp, 1997, 실험 2)
    - 데이터: Chopin 에튀드 Op.10 No.3 1–5마디. 타이밍만 변화. 전문가 15, 학생 9, 평균 3, 전문가 타이밍 PCA 성분 3 = 30개. 평가자 12명.
- 최소 거리 가설로 설명했다. 청취자마다 이상형이 있고 그 이상형들이 평균 주변에 퍼져 있으면, 평균 연주가 평균적으로 가장 가깝다는 것. 평가자 각자의 본인 연주를 이상형으로 삼아 그 연주와의 유사도(템포 차이 + 타이밍 곡선 상관)로 순위를 예측했고, 평균 순위는 R = .82, 개인 수준에서는 10명 중 8명이 유의함 (Repp, 1997, Table 2). Repp 스스로 "매우 예비적"이라고 함
- 한계: 연주와 이상형 사이의 전체 거리 하나만 썼고(어느 방향으로 벗어났는지는 구분하지 않음), 이상형을 평가자 본인의 연주로 쟀으며(연주하지 않는 청취자에게는 적용 불가), 곡은 실험마다 하나씩, 평가자 12명

최근 연구들도 청취자를 나누지 않았다

- 곡 중심에서의 정서 편차를 예측했지만 청취자는 평균만 사용. (Ching & Widmer, 2026, "Learning to Predict Performance-induced Emotion Differences in Classical Piano Music", ISMIR 2026)
    - 데이터: CP-WTC. Bach 평균율 1권 48곡, 피아니스트 6명의 상업 녹음, 첫 8마디, 288구간.

- 악보 내용과 연주 스타일을 분리했지만 청취 평가는 11명 평균 ("Disentangling Score Content and Performance Style for Joint Piano Rendering and Transcription", arXiv 2509.23878, 2025)
    - 데이터: ASAP 967연주, ATEPP 11,674연주(피아니스트 49명), MuseScore 악보 75,913개와 YouTube 커버 전사.
- Repp(1997) 이후, 연주의 벗어남을 방향별로 나누고 청취자 개인 선호와 겹쳐 본 연구는 찾지 못하였음

현상

- 평균 연주는 품질↑ 개성↓, 품질-개성 r = −.73 (Repp, 1997). Repp는 최소 거리 가설로 설명함
- 설득력에는 합의가 없다. 단위 내 신뢰도는 0.43이었고 (우리 분석, R5), 설득력과 vel_range 차이의 상관은 0.011
    - 데이터: 둘 다 PercePiano D960.

가설 (최소 거리 가설의 확장)

- 관습 방향으로 더/덜 한 양(α)은 공유 축으로 읽혀 합의가 생기고, 다른 방향(ρ)은 개인 선호로 읽혀 갈린다
    - 데이터(예정): PercePiano D960 개별 평가, 정렬 손 특징, 무표정 렌더.
- Repp의 "이상형"을 평가자 본인 연주 대신 평가에서 추정한 선호 방향(β)으로 대체한다
- 두 가설을 가르는 검정: 최소 거리 가설이 맞다면 |α|로 벗어나도 ‖ρ‖로 벗어나도 평가자 간 의견이 똑같이 갈려야 하고, 층 가설이 맞다면 의견이 갈리는 것은 ‖ρ‖에서만 나타나야 함
    - 방법: ‖ρ‖, |α|, ‖r‖ 각각과 설득력 평균·평가자 간 SD의 단위 내 순위 상관 비교